

Classificació automàtica de residus domèstics

Júlia Morán - 1667730, Adrián Prego - 1672251, Maria Muñoz - 1668438
Grup VC35

Abstract— This project developed and evaluated a computer vision system for the automatic classification of household waste from images. The system considered six categories: cardboard, glass, metal, paper, plastic, and trash. Different approaches were compared, including classical methods based on HOG + HSV and LBP + HSV descriptors combined with traditional classifiers, a CNN trained from scratch, and a transfer learning approach based on MobileNetV2. The public Trash Type Image Dataset, derived from TrashNet, was used, and the models were evaluated mainly using the F1-macro metric and confusion matrices. The results showed that LBP + HSV achieved better performance than HOG + HSV, highlighting the importance of texture information for this problem. The best overall results were obtained with MobileNetV2, achieving an F1-macro above 81%, confirming the effectiveness of transfer learning for intelligent recycling applications.

Keywords— Image classification, household waste, intelligent recycling, computer vision, CNN, deep learning.

1 INTRODUCCIÓ

La classificació automàtica de residus és un problema rellevant dins l'àmbit de la visió per computador, especialment per la necessitat de millorar els sistemes de reciclatge i reduir l'impacte ambiental. La gran variabilitat visual dels residus i la similitud entre algunes categories dificulten aquesta tasca, fent necessari l'ús de tècniques avançades de classificació d'imatges.

Tradicionalment, aquest problema s'ha abordat mitjançant descriptors manuals basats en color, textura o forma combinats amb classificadors clàssics. Més recentment, les tècniques de deep learning, i especialment les xarxes neuronals convolucionals, han demostrat resultats molt competitius en tasques de classificació visual.

L'objectiu d'aquest treball és desenvolupar i comparar diferents enfocaments per classificar imatges de residus en sis categories: cardboard, glass, metal, paper, plastic i trash. Per fer-ho, s'utilitzaran tant mètodes clàssics basats en descriptors visuals com models de deep learning i transfer learning sobre un conjunt de dades públic. Finalment, s'analitzaran els resultats, les matrius de confusió i els principals errors dels models.

2 OBJECTIUS PRINCIPALS

L'objectiu d'aquest treball és desenvolupar i estudiar un sistema automàtic de classificació de residus a partir d'imatges, analitzant tant enfocaments clàssics de visió per computador com mètodes basats en deep learning.

En concret, es plantegen els objectius següents:

- Estudiar el problema de classificació de residus i els principals mètodes proposats a la literatura.
- Implementar un enfocament clàssic basat en descriptors visuals i classificadors tradicionals per establir una referència inicial.
- Implementar un model basat en xarxes neuronals convolucionals per abordar la mateixa tasca de classificació.
- Comparar el rendiment dels dos enfocaments mitjançant mètriques de classificació i analitzar-ne avantatges, limitacions i errors més freqüents.

3 ESTAT DE L'ART

La classificació automàtica de residus ha evolucionat significativament, passant de l'ús de descriptors manuals a models de *deep learning* que aprenen directament de les imatges [1].

3.1 Mètodes basats en descriptors manuals

Històricament, els sistemes se centraven en *pipelines* de segmentació i extracció de característiques. S'utilitzaven tècniques com la binarització d'Otsu o l'algorisme de Canny per separar el residu del fons [1]. Posteriorment, s'extreien descriptors de color, textura o forma (com HOG o SIFT) per alimentar classificadors com KNN o SVM [1]. No obstant això, aquests mètodes presenten limitacions davant la variabilitat dels residus, amb precisions habitualment al voltant del 60–70% [2].

3.2 Arquitectures de Deep Learning i models recents

L'aparició de les xarxes neuronals convolucionals (CNN) ha permès aprendre automàticament les característiques de les dades [1]. En el dataset *TrashNet* [2], s'ha observat que arquitectures com **ResNet-18** són de les més estables, amb un 88,66% de precisió, superant models com VGG-16 (76,94%) o Inception (87,71%) [1].

Recentment, s'han proposat millores que han elevat el rendiment del sistema:

- **MLH-CNN (2021)**: Shi et al. proposen una xarxa híbrida inspirada en VGG però més simple, assolint una precisió del **92,6%** sobre *TrashNet* [4].
- **WasteNet (2020)**: White et al. presenten un model CNN optimitzat per dispositius de baix consum, arribant a un **97%** de precisió en test [3].

L'estat de l'art actual se centra en augmentar la precisió mitjançant arquitectures híbrides [4] i en garantir l'eficiència computacional per aplicacions de reciclatge intel·ligent [3].

4 DADES

Per a aquest treball s'utilitza el conjunt de dades públic *Trash Type Image Dataset* [5], disponible a Kaggle, dissenyat per a tasques de classificació automàtica de residus mitjançant visió per computador.

El dataset conté un total de 2527 imatges en format JPG, amb resolució de 512×384 píxels, agrupades en sis categories corresponents a diferents tipus de residus reciclables i no reciclables: cartró, vidre, metall, paper, plàstic i rebuig.

Classe	Cardboard	Glass	Metal	Paper	Plastic	Trash
Imatges	403	501	410	594	482	137

Taula 1: Distribució de classes del dataset utilitzat.

La distribució de mostres per classe no és completament equilibrada, tal com mostra la Taula 1, amb una major representació de les classes *paper* i *glass*, i una clara infrarepresentació de la classe *trash*. Aquest desbalanceig, juntament amb la variabilitat en orientació, il·luminació, fons i aparença dels objectes, fa que el conjunt sigui representatiu d'escenaris reals i introdueixi un repte addicional per a la classificació dels residus.

5 PROPOSTA

La proposta consisteix a desenvolupar un sistema supervisat de classificació d'imatges de residus domèstics utilitzant tècniques de visió per computador i deep learning. El sistema seguirà un flux format per preprocessament de les imatges, extracció de característiques o aprenentatge automàtic de representacions, classificació i avaluació dels resultats.

El conjunt de dades es dividirà en subconjunts d'entrenament, validació i test. Les imatges es redimensionaran a 128×128 píxels i, en el cas de les xarxes neuronals, es normalitzaran al rang [0,1]. Per als mètodes clàssics, les característiques extretes es normalitzaran mitjançant *StandardScaler*. A més, en els models de deep learning s'aplicaran tècniques de *data augmentation* per augmentar la variabilitat del conjunt de dades i reduir el sobreajustament.

Es compararan dos enfocaments principals. El primer utilitzarà descriptors manuals com HOG, LBP i histogrames HSV combinats amb classificadors tradicionals com SVM, k-NN i Random Forest. El segon enfocament estarà basat en xarxes neuronals convolucionals, incloent una CNN senzilla entrenada des de zero i models de *transfer learning* com MobileNetV2, tant amb la xarxa congelada com aplicant *fine-tuning* sobre les últimes capes.

Finalment, s'avaluarà el rendiment dels models mitjançant mètriques de classificació i matrius de confusió, analitzant especialment els errors entre classes visualment similars. A causa del desbalanceig existent entre classes, els resultats es compararan principalment utilitzant el F1-macro, ja que permet avaluar de manera més equilibrada el comportament global del sistema.

6 EXPERIMENTS, RESULTATS I ANÀLISI

6.1 Baseline amb models de Machine Learning

Per a l'avaluació dels mètodes clàssics de classificació s'ha utilitzat el conjunt de dades Trash Type Image Dataset, dividint les dades en subconjunts d'entrenament i test mitjançant una partició estratificada del 80% i 20%, respectivament.

6.1.1 Descriptors HOG + HSV

Inicialment, s'ha utilitzat una combinació de descriptors HOG (*Histogram of Oriented Gradients*) i histogrames de color HSV. Les característiques HOG descriuen la forma i els contorns dels objectes, mentre que HSV aporta informació relacionada amb el color i el material dels residus.

A partir d'aquestes característiques s'han entrenat tres classificadors supervisats: SVM, Random Forest i k-NN. Per optimitzar els models s'ha aplicat una cerca d'hiperparàmetres mitjançant *Grid Search* amb validació creuada, utilitzant el F1-macro com a mètrica principal degut al desbalanceig de classes.

Model	Accuracy	Precision	Recall	F1-macro
SVM	0.6937	0.7407	0.6521	0.6739
Random Forest	0.6877	0.7447	0.6334	0.6557
k-NN	0.4960	0.5610	0.4691	0.4652

Taula 2: Resultats dels classificadors clàssics utilitzant descriptors HOG + HSV.

Els resultats mostren que SVM és el model amb millor rendiment global, obtenint un F1-macro de 0.6739. Tot i obtenir resultats acceptables, s'observen confusions entre classes visualment similars com *plastic*, *glass* i *metal*, evidenciant les limitacions dels descriptors manuals davant la variabilitat visual del conjunt de dades.




Fig. 1: Matrius de confusió dels classificadors clàssics sobre el conjunt de test amb HOG + HSV.

6.1.2 Descriptors LBP + HSV

Per tal de millorar la representació de les textures, posteriorment s'ha substituït HOG pel descriptor LBP (*Local Binary Patterns*), mantenint els histogrames HSV. LBP descriu patrons locals d'intensitat i és especialment útil per diferenciar textures present en materials com cartró, paper o metall.

Utilitzant la mateixa metodologia experimental i els mateixos classificadors, s'han obtingut els resultats mostrats a la Taula 3.

Model	Accuracy	Precision	Recall	F1-macro
Random Forest	0.8221	0.8376	0.7831	0.7988
SVM	0.7431	0.7566	0.7288	0.7392
k-NN	0.7411	0.7230	0.7046	0.7117

Taula 3: Resultats dels classificadors clàssics utilitzant descriptors LBP + HSV.

Els resultats mostren una millora significativa respecte als descriptors HOG + HSV, especialment en el cas del model Random Forest, que aconsegueix un F1-macro proper al 80%.

Aquest comportament suggereix que, en aquest problema, la informació de textura és més discriminativa que la informació basada únicament en vores i gradients. Materials com cartró, paper, metall o plàstic comparteixen sovint formes similars, però presenten textures superficials diferents que poden ser capturades de manera més efectiva pels descriptors LBP.




Fig. 2: Matrius de confusió sobre el conjunt de test amb LBP + HSV.

A partir de les matrius de confusió, s'observa que el model Random Forest presenta el millor comportament global, amb una diagonal principal més marcada i menys dispersió d'errors respecte als altres classificadors. Les principals confusions es mantenen entre classes visualment similars, especialment entre *paper* i *cardboard*, i entre *plastic*, *glass* i *metal*, tot i que amb una reducció d'errors respecte a l'enfocament HOG+HSV. La classe *trash* continua sent la més difícil de classificar a causa del desbalanceig del conjunt de dades.

6.2 Models de Deep Learning

6.2.1 CNN bàsica

Com a primer enfocament de deep learning, s'ha implementat una xarxa neuronal convolucional (CNN) entrenada des de zero. El model consta de tres blocs convolucionals amb un nombre creixent de filtres (32, 64 i 128), seguits d'una capa densa de 128 neurones i una capa de Dropout del 50% per reduir l'overfitting. La sortida es defineix mitjançant una capa softmax per a les sis classes del problema.

Per millorar la capacitat de generalització del model, s'han aplicat tècniques de data augmentation sobre el conjunt d'entrenament. En concret, s'han utilitzat transformacions aleatòries de rotació fins a $\pm 20^\circ$, desplaçaments horitzontals i verticals fins al 10% de la dimensió de la imatge, zoom aleatori fins al 10%, i gir horitzontal. Aquestes transformacions permeten augmentar la variabilitat del conjunt de dades i reduir l'overfitting. A més, s'ha utilitzat early stopping monitoritzant la pèrdua en validació per evitar el sobreentrenament.

El model s'ha entrenat durant 30 èpoques, utilitzant l'optimitzador Adam i la funció de pèrdua d'entropia creuada categòrica.

Els resultats obtinguts es mostren a la Taula 4. El model aconsegueix un F1-macro de 0.68 aproximadament, amb una accuracy del 69.76%.

Model	Accuracy	Precision	Recall	F1-macro
CNN	0.6976	0.6915	0.6842	0.6826

Taula 4: Resultats de la CNN entrenada des de zero.

La matriu de confusió de la CNN mostra bons resultats en classes com cardboard i paper, però es mantenen confusions entre glass i plastic a causa de les similituds visuals entre aquests materials.




Fig. 3: Matriu de confusió CNN entrenada des de zero.

Els resultats mostren que la CNN bàsica obté un rendiment inferior als millors models clàssics. Probablement això es deu tant a la simplicitat de l'arquitectura com a la mida reduïda del conjunt de dades, fet que dificulta l'aprenentatge de representacions robustes.

6.2.2 MobileNetV2 amb capes congelades

Com a segon enfocament de deep learning s'ha utilitzat transfer learning amb l'arquitectura MobileNetV2 preentrenada amb ImageNet. En aquest primer cas, s'han congelat totes les capes del model base, utilitzant-lo com a extractor de característiques fixes, i s'ha afegit una capa de classificació adaptada al problema amb global average pooling, una capa fully connected de 128 neurones i una capa de Dropout per reduir l'overfitting.

El model s'ha entrenat únicament sobre les capes finals, aprofitant les representacions visuals apreses prèviament. Durant l'entrenament també s'ha aplicat data augmentation sobre el conjunt d'entrenament per millorar la generalització. Els resultats de la Taula 5 mostren una millora significativa respecte a la CNN entrenada des de zero

Model	Accuracy	Precision	Recall	F1-macro
MobileNetV2	0.8004	0.7825	0.7810	0.7786

Taula 5: Resultats MobileNetV2 entrenada amb capes congelades.

Aquest comportament confirma l'efectivitat del transfer learning en problemes amb datasets limitats, ja que permet reutilitzar representacions generals de baix nivell apreses en grans conjunts de dades.




Fig. 4: Matriu de confusió MobileNetV2.

La matriu de MobileNetV2 mostra les principals confusions concentrades a metal confós amb glass i plastic amb glass, reflectint un altre cop la dificultat de distingir materials brillants i transparents.

6.2.3 MobileNetV2 amb fine-tuning

En una segona etapa s'ha aplicat fine-tuning sobre el model MobileNetV2, descongelant parcialment les últimes

30 capes del model base i reentrenant-lo amb una taxa d'aprenentatge reduïda. Aquest procés permet ajustar les característiques més específiques del model a la distribució del dataset utilitzat.

Per evitar sobreajustament s'ha mantingut l'estratègia de data augmentation i s'ha utilitzat early stopping basat en la pèrdua de validació.

Model	Accuracy	Precision	Recall	F1-macro
MobileNetV2 Fine-Tuning	0.8379	0.8293	0.8136	0.8193

Taula 6: Resultats MobileNetV2 amb Fine-Tuning.

Els resultats mostren una millora addicional respecte al model anterior, assolint com s'observa a la Taula 6 un F1-macro superior al 81%, confirmant que l'ajust parcial del model preentrenat permet obtenir representacions més adaptades al domini del problema.




Fig. 5: Matriu de confusió MobileNetV2 amb Fine-Tuning.

Amb el fine-tuning, s'observa una millora notable a metal, que passa de 59 a 70 encerts, i a plastic, que millora de 66 a 73. Les confusions entre plastic i glass es redueixen lleugerament (de 19 a 17), tot i que continuen sent les més freqüents.

6.3 Anàlisi d'errors

A la Figura 6 es mostren alguns exemples d'errors de classificació del model MobileNetV2 amb fine-tuning. S'observa que moltes de les confusions es produeixen entre classes visualment similars. Per exemple, alguns objectes metàl·lics es classifiquen com *paper* a causa de la seva forma plana, mentre que també apareixen confusions entre *glass* i *metal* provocades pels reflexos i superfícies brillants compartides entre aquests materials.

De manera similar, algunes mostres de *plastic* es classifiquen com *glass* per les similituds visuals entre envasos transparents. També s'observen errors entre *cardboard* i *paper*, especialment en objectes amb etiquetes impreses o textures semblants.



Fig. 6: Errors de classificació del model MobileNetV2 amb fine-tuning.

Aquestes confusions mostren la dificultat del problema i les limitacions del model davant materials amb aparences molt similars.

7 CONCLUSIONS

Els experiments realitzats mostren que la classificació automàtica de residus mitjançant tècniques de visió per ordinador es pot abordar amb diferents enfocaments de machine learning i deep learning.

En els mètodes clàssics, s'ha observat que la combinació de descriptors LBP i histogrames de color HSV millora clarament el rendiment respecte als enfocaments basats en HOG + HSV. Aquest comportament suggereix que la informació de textura és especialment útil per discriminar materials amb aparences similars.

Pel que fa a la CNN entrenada des de zero, els resultats han estat bastant limitats. Probablement això es deu tant a la simplicitat de l'arquitectura utilitzada com a la mida reduïda del conjunt de dades, fet que dificulta l'aprenentatge de representacions visuals robustes quan el model s'entrena completament des de zero.

Finalment, l'ús de transfer learning amb MobileNetV2 ha permès obtenir els millors resultats globals, especialment després d'aplicar fine-tuning sobre les últimes capes del model. Tot i així, la millora no ha estat tan gran com es podria esperar, probablement perquè el conjunt de dades és relativament petit i algunes classes presenten característiques visuals molt similars.

En general, els resultats obtinguts mostren que les tècniques basades en transfer learning són especialment adequades per a problemes de classificació visual amb datasets limitats. Tot i que la millora respecte als mètodes clàssics no ha estat molt gran, es considera que amb més proves, arquitectures més complexes o models preentrenats més avançats es podrien obtenir resultats significativament millors. De la mateixa manera, tècniques addicionals d'augmentació de dades, regularització o un conjunt de dades més gran probablement permetrien aprofitar millor el potencial del deep learning en aquest problema.

REFERÈNCIES

- [1] V. Ruiz, Á. Sánchez, J. F. Vélez i B. Raducanu, "Automatic Image-Based Waste Classification," *Proceedings of the International Work-Conference on Analysis of Images and Objects*, 2019.
- [2] G. Yang and M. Thung, "Classification of Trash for Recyclability Status," Stanford CS229 Project Report, 2016.
- [3] G. White, C. Cabrera, A. Palade, F. Li i S. Clarke, "WasteNet: Waste Classification at the Edge for Smart Bins," *arXiv:2006.05873*, 2020.
- [4] C. Shi, C. Tan, T. Wang i L. Wang, "A Waste Classification Method Based on a Multilayer Hybrid Convolution Neural Network," *Applied Sciences*, vol. 11, no. 18, 8572, 2021.
- [5] F. Nekouei, "Garbage Image Dataset," Kaggle, 2023. Disponible a: <https://www.kaggle.com/datasets/farzadnekouei/trash-type-image-dataset>